

PCA061225

December 6, 2025

1 Análisis de componentes principales PCA

```
[2]: # Parte 1 - Librerías y datos

#Tratamiento de los datos
import numpy as np
import pandas as pd
import statsmodels.api as sm

#Gráficos
import matplotlib.pyplot as plt
import matplotlib.font_manager
from matplotlib import style
style.use('ggplot') or plt.style.use('ggplot')

#Preprocesado y modelado
from sklearn.decomposition import PCA
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import scale

#Warnings
import warnings
warnings.filterwarnings('ignore')
```

```
[3]: USArrests = sm.datasets.get_rdataset("USArrests", "datasets")
```

```
[4]: datos = USArrests.data
```

El set de datos USArrests contiene el porcentaje de asaltos (Assault), asesinatos (Murder) y violaciones (Rape) por cada 100,000 habitantes para cada uno de los 50 estados de USA (1973). Además, también incluye el porcentaje de la población de cada estado que vive en zonas rurales (UrbanPoP).

```
[5]: #Análisis exploratorio de los datos
datos.head()
```

```
[5]:
```

	Murder	Assault	UrbanPop	Rape
rownames				
Alabama	13.2	236	58	21.2
Alaska	10.0	263	48	44.5
Arizona	8.1	294	80	31.0
Arkansas	8.8	190	50	19.5
California	9.0	276	91	40.6

2 Exploración inicial

Los dos aspectos principales a tener en cuenta cuando se quiere realizar un PCA es identificar la media y la dispersión de las variables

```
[6]: datos.mean()
```

```
[6]: Murder      7.788
      Assault    170.760
      UrbanPop   65.540
      Rape       21.232
      dtype: float64
```

La media de las variables muestra que hay tres veces más violaciones que asesinatos y 8 veces más asaltos que violaciones

```
[7]: datos.var()
```

```
[7]: Murder      18.970465
      Assault    6945.165714
      UrbanPop   209.518776
      Rape       87.729159
      dtype: float64
```

La varianza es muy distinta entre cada variable, en el caso de Assault, la varianza es varios órdenes de magnitud superior al resto.

```
[9]: # Escalado de datos
      scaler = StandardScaler()
      datos_escalados = scaler.fit_transform(datos)
```

Si no se estandarizan las variables para que tendan media cero y desviación estándar de uno antes de realizar el estudio PCA, la variable Assault, que tiene una media y dispersión muy superior al resto, dominará la mayoría de los componentes principales

```
[11]: # Crear modelo y entrenar PCA
      pca = PCA()
      pca.fit(datos_escalados)
```

```
[11]: PCA()
```

La clase `sklearn.decomposition.PCA` incorpora las principales funcionalidades que se necesitan a la hora de trabajar con modelos PCA. El argumento `n_components` determina el número de componentes calculados. Si se indica `None`, se calculan todas las posibles ($\min(\text{filas}, \text{columnas}) - 1$).

```
[13]: # El modelo entrenado
modelo_pca = pca
```

Una vez entrenado el objeto PCA, puede accederse a toda la información de las componentes creadas.

```
[14]: # Resultado crudo de componentes
modelo_pca.components_
```

```
[14]: array([[ 0.53589947,  0.58318363,  0.27819087,  0.54343209],
        [-0.41818087, -0.1879856 ,  0.87280619,  0.16731864],
        [-0.34123273, -0.26814843, -0.37801579,  0.81777791],
        [-0.6492278 ,  0.74340748, -0.13387773, -0.08902432]])
```

```
[15]: pd.DataFrame(
        data = modelo_pca.components_,
        columns = datos.columns,
        index = ['PC1', 'PC2', 'PC3', 'PC4']
    )
```

```
[15]:      Murder  Assault  UrbanPop  Rape
PC1   0.535899  0.583184  0.278191  0.543432
PC2  -0.418181 -0.187986  0.872806  0.167319
PC3  -0.341233 -0.268148 -0.378016  0.817778
PC4  -0.649228  0.743407 -0.133878 -0.089024
```

Los renglones se corresponden con las componentes principales (ordenadas de mayor a menos varianza explicada). Las columnas se corresponden con las variables de entrada

$$PC1 = 0.535899 * \text{Murder} + 0.583184 * \text{Assault} + 0.278191 * \text{UrbanPop} + 0.543432 * \text{Rape}$$

Alabama 13.2 236 58 21.2


$$0.535899 * 13.2 + 0.583184 * 236 + 0.278191 * 58 + 0.543432 * 21.2 =$$

Los pesos asignados en la primera componente a las variables Assault, Murder y Rape son aproximadamente iguales entre ellos y superiores al asignado a UrbanPoP. Esto significa que la primera componente recoge mayoritariamente la información correspondiente a los delitos. En la segunda componente, es la variable UrbanPoP es la que tiene con diferencia mayor peso, por lo que se corresponde principalmente con el nivel de urbanización del estado. Si bien en este ejemplo la interpretación de las componentes es bastante clara, no en todos los casos ocurre lo mismo, sobre todo a medida que aumenta el número de variables.

La influencia de las variables en cada componente puede analizarse visualmente con un gráfico de tipo heatmap.

```
[16]: # Mapa de calor (Heatmap) componentes

fig, ax = plt.subplots(nrows = 1, ncols = 1, figsize=(2,2))
componentes = modelo_pca.components_
plt.imshow(componentes.T, cmap = 'viridis', aspect='auto')
plt.yticks(range(len(datos.columns)), datos.columns)
plt.xticks(range(len(datos.columns)), np.arange(modelo_pca.n_components_) + 1)
plt.grid(False)
plt.colorbar();
```



Una vez calculadas las componentes principales, se puede conocer la varianza explicada por cada una de ellas, la proporción respecto al total y la proporción de varianza acumulada. Esta información está almacenada en los atributos `explained_variance_` y `explained_variance_ratio_` del modelo.

```
[17]: # Porcentaje de varianza explicada por cada componente
# =====
print(modelo_pca.explained_variance_ratio_)

fig, ax = plt.subplots(nrows=1, ncols=1, figsize=(6, 4))
ax.bar(
    x      = np.arange(modelo_pca.n_components_) + 1,
    height = modelo_pca.explained_variance_ratio_
)


for x, y in zip(np.arange(len(datos.columns)) + 1, modelo_pca.
    ↪explained_variance_ratio_):
    label = round(y, 2)
    ax.annotate(
        label,
        (x,y),
        textcoords="offset points",
        xytext=(0,10),
        ha='center'
    )
```

```

ax.set_xticks(np.arange(modelo_pca.n_components_) + 1)
ax.set_ylim(0, 1.1)
ax.set_title('Porcentaje de varianza explicada por cada componente')
ax.set_xlabel('Componente principal')
ax.set_ylabel('Por. varianza explicada');

```

```
[0.62006039 0.24744129 0.0891408 0.04335752]
```



En este caso, la primera componente explica el 62% de la varianza observada en los datos y la segunda el 24.7%. Las dos últimas componentes no superan por separado el 1% de varianza explicada.

```

[18]: # Porcentaje de varianza explicada acumulada
# =====
prop_varianza_acum = modelo_pca.explained_variance_ratio_.cumsum()
print(prop_varianza_acum)

fig, ax = plt.subplots(nrows=1, ncols=1, figsize=(6, 4))
ax.plot(
    np.arange(len(datos.columns)) + 1,
    prop_varianza_acum,
    marker = 'o'
)

```


```

for x, y in zip(np.arange(len(datos.columns)) + 1, prop_varianza_acum):
    label = round(y, 2)
    ax.annotate(
        label,
        (x,y),
        textcoords="offset points",
        xytext=(0,10),
        ha='center'
    )

ax.set_ylim(0, 1.1)
ax.set_xticks(np.arange(modelo_pca.n_components_) + 1)
ax.set_title('Porcentaje de varianza explicada acumulada')
ax.set_xlabel('Componente principal')
ax.set_ylabel('Por. varianza acumulada');

```

[0.62006039 0.86750168 0.95664248 1.]



Si se empleasen únicamente las dos primeras componentes se conseguiría explicar el 87% de la varianza observada.

Ahora voy a entrenar de nuevo el modelo para que solo me queden 2 variables.

```
[20]: pca = PCA(n_components = 2)
      pca.fit(datos_escalados)
      modelo_pca = pca
```

```
[21]: proyecciones = modelo_pca.transform(datos_escalados)
```

```
[24]: proyecciones = pd.DataFrame(
      proyecciones,
      columns = ['PC1', 'PC2'],
      index = datos.index
    )
```

```
[25]: proyecciones.head()
```

```
[25]:
```

	PC1	PC2
rownames		
Alabama	0.985566	-1.133392
Alaska	1.950138	-1.073213
Arizona	1.763164	0.745957
Arkansas	-0.141420	-1.119797
California	2.523980	1.542934

```
[26]: datos.head()
```

```
[26]:
```

	Murder	Assault	UrbanPop	Rape
rownames				
Alabama	13.2	236	58	21.2
Alaska	10.0	263	48	44.5
Arizona	8.1	294	80	31.0
Arkansas	8.8	190	50	19.5
California	9.0	276	91	40.6

```
[27]: datos_escalados[:2]
```

```
[27]: array([[ 1.25517927,  0.79078716, -0.52619514, -0.00345116],
      [ 0.51301858,  1.11805959, -1.22406668,  2.50942392]])
```

```
[33]: (0.535899 * 1.25517927) + (0.583184 * 0.79078716) + (0.278191 * -0.52619514) +
      ↪(0.543432 * -0.00345116)
```

```
[33]: 0.9855655117583101
```

```
[34]: (0.535899 * 0.51301858) + (0.583184 * 1.11805959) + (0.278191 * -1.22406668) +
      ↪(0.543432 * 2.50942392)
```

```
[34]: 1.9501375338555402
```

```
[ ]:
```